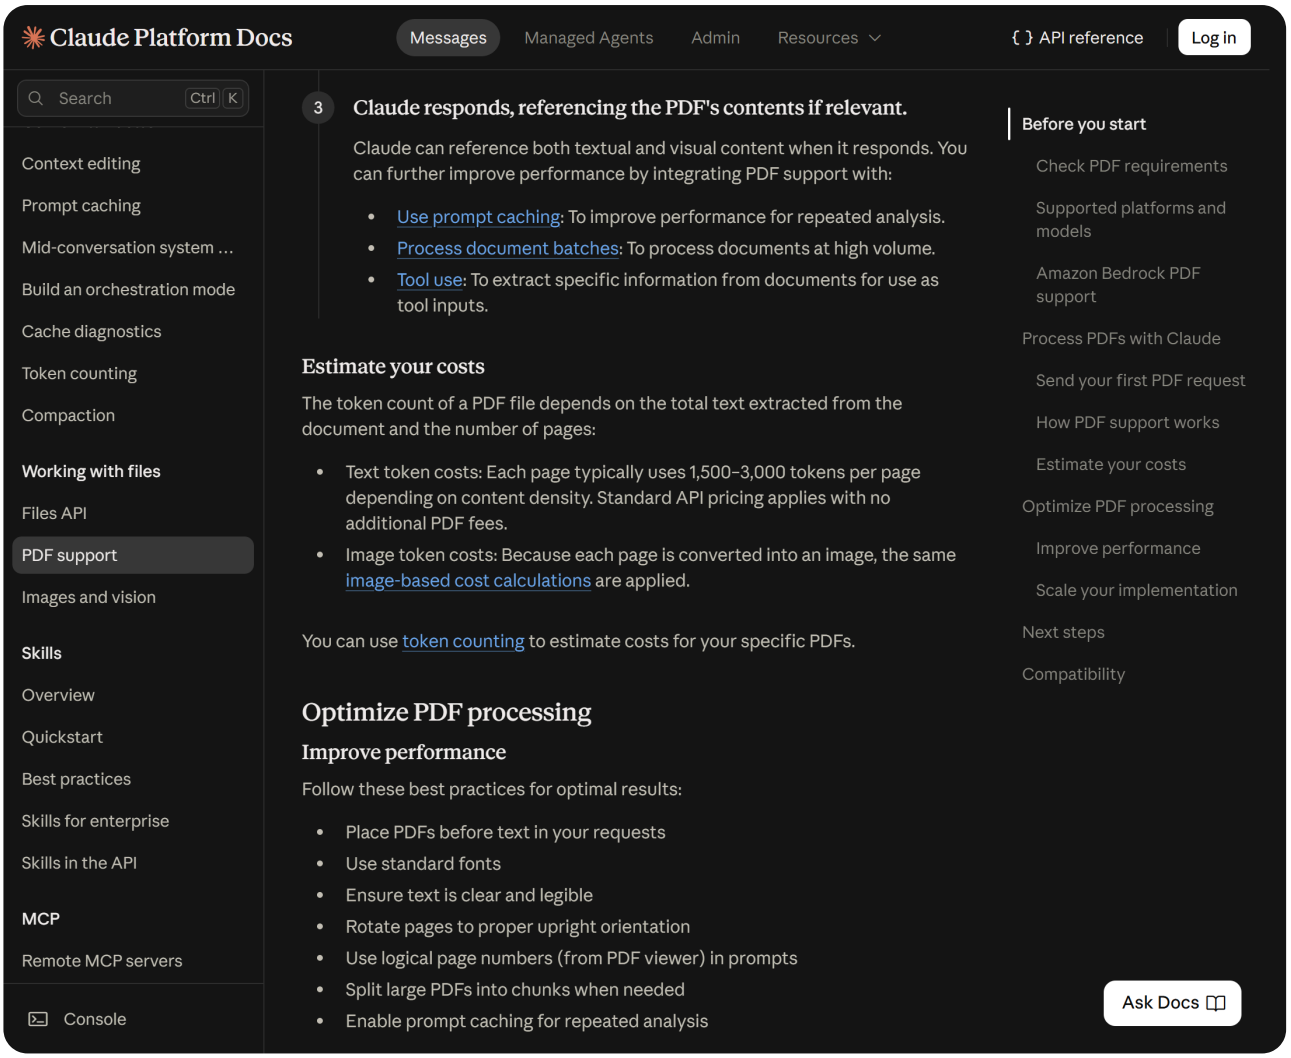
AI, BUT USEFUL · EP.06

وفّر توكنز Claude: حوّل ملفاتك قبل ما ترفعها

ملف PDF من 20 صفحة ممكن يوصل لتقدير رسمي بين 30 و60 ألف توكن، للنص وحده. بأداة مجانية من مايكروسوفت نزل نفس الملف لحوالي 10 آلاف. هون الخطوات والقياس والحدود، بدون مبالغة.

1. ليش الملف بياكل توكنز؟

التوكن هو الوحدة اللي Claude بيعدّ فيها اللي بيقراه وبيكتبه. لما ترفع PDF، Claude ما بياخد النص بس: كل صفحة بتتحوّل لنص **ولصورة كمان**، وبيتحسب عليك الاتنين. وثائق Anthropic الرسمية بتقول:



المصدر: Claude Platform Docs ← PDF support ← Estimate your costs.

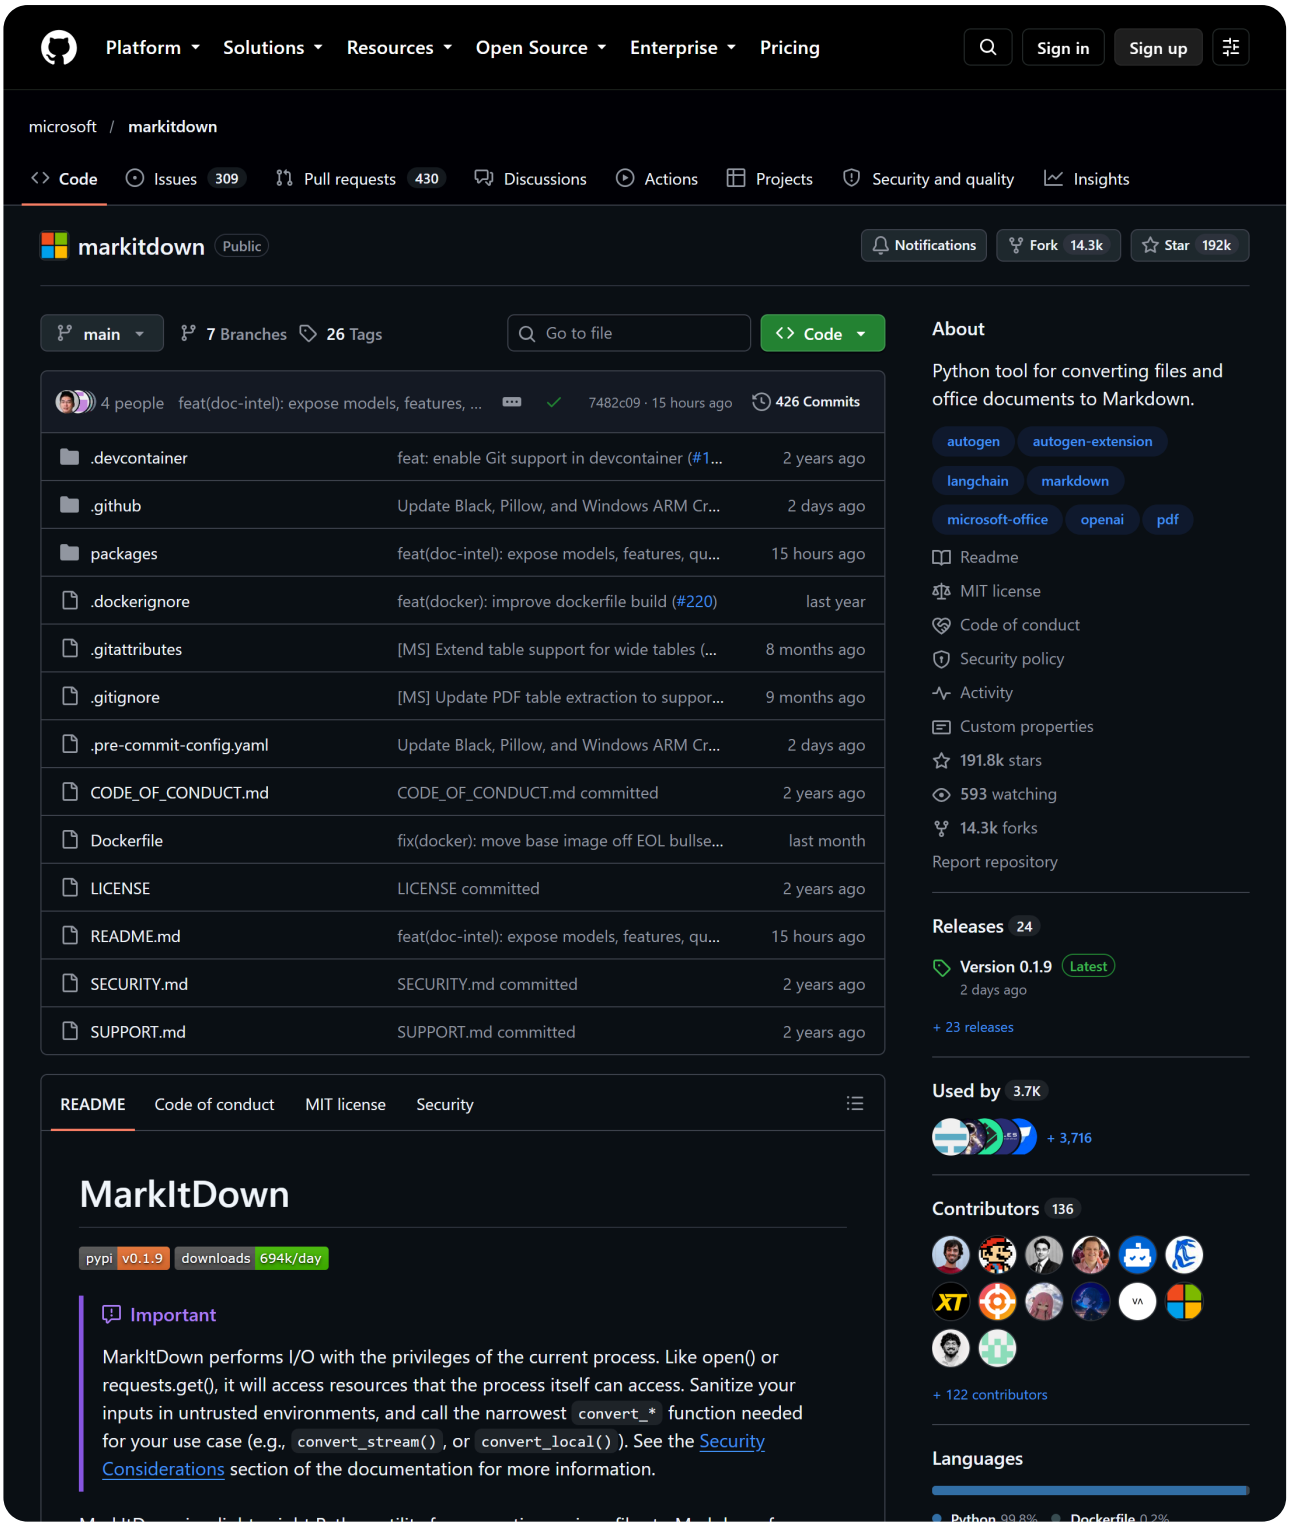
1,500–3,000
توكن للنص في الصفحة الوحدة (رسمي)

صورة +
لكل صفحة، وتكلفتها بتنحسب فوق النص

يعني ملف 20 صفحة: من 30,000 إلى 60,000 توكن للنص وحده (20 × 1,500 إلى 20 × 3,000)، وبعدها تكلفة الصور. هاد تقدير رسمي، والرقم الفعلي بيختلف حسب الملف.

2. الحل: MarkItDown من مايكروسوفت

أداة مجانية ومفتوحة المصدر (رخصة MIT)، بتحوّل الملفات لنص Markdown: نص عادي نظيف مع الحفاظ على العناوين والقوائم والجداول. بتدعم PDF وWord وPowerPoint وExcel وغيرها. وصف مشروعها الرسمي بيقول إنه «token-efficient Markdown».



المصدر: github.com/microsoft/markitdown (حوالي 191.8 ألف نجمة وقت التصوير).

3. التثبيت والاستعمال

1. لازم يكون عندك **Python** نسخة 3.10 أو أحدث (حتى 3.14 حسب README الرسمي).

2 افتح الـ Terminal وثبّت الأداة بأمر واحد:

```
pip install 'markitdown[all]'
```

3 حوّل الملف:

```
markitdown path-to-file.pdf -o document.md
```

4 **ارفع ملف الـ .md على Claude بدل الـ PDF الأصلي.**

Command-Line

```
markitdown path-to-file.pdf > document.md
```

Or use `-o` to specify the output file:

```
markitdown path-to-file.pdf -o document.md
```

You can also pipe content:

```
cat path-to-file.pdf | markitdown
```

Optional Dependencies

MarkItDown has optional dependencies for activating various file formats. Earlier in this document, we installed all optional dependencies with the `[all]` option. However, you can also install them individually for more control. For example:

```
pip install 'markitdown[pdf, docx, pptx]'
```

المصدر: README الرسمي، قسم Command-Line.

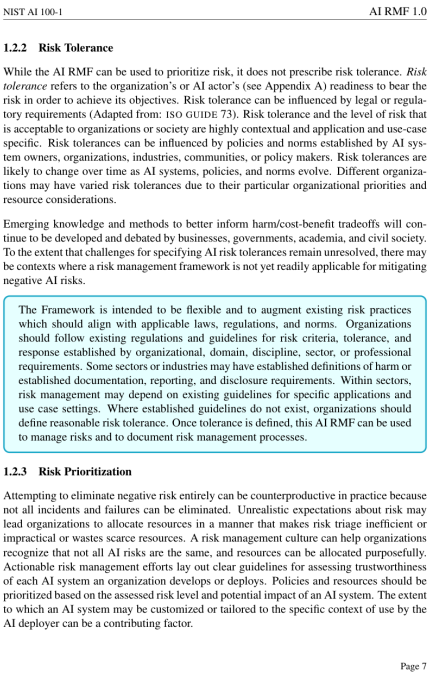
إذا بدك تثبّت صيغ محددة بس: `'pip install 'markitdown[pdf, docx, pptx]`

4. القياس الحقيقي

جرّبناها على أول 20 صفحة من ملف حكومي مجاني (NIST AI 100-1، إطار إدارة مخاطر الذكاء الاصطناعي):

البند	القيمة
حجم ملف الـ PDF (20 صفحة)	**1,766,051 bytes**
حجم ملف الـ Markdown الناتج	**43,387 bytes**
عدد الكلمات	**4,484**
التوكنز بعد التحويل (قياس تقريبي)	**≈ 9,665**
التقدير الرسمي للنص وحده (20 صفحة)	**30,000 – 60,000**
مدة التحويل	**≈ 2.5 s**

انتبه للرقم: قسنا التوكنز بـ tokenizer عام (cl100k_base)، مش tokenizer تبع Claude، فالرقم تقريبي وClaude ممكن يعدّ أعلى شوي. والمقارنة بين تقدير رسمي وقياس تقريبي، مش بين قياسين متطابقين.



NIST AI 100-1 AI RMF 1.0

1.2.2 Risk Tolerance

While the AI RMF can be used to prioritize risk, it does not prescribe risk tolerance. *Risk tolerance* refers to the organization's or AI actor's (see Appendix A) readiness to bear the risk in order to achieve its objectives. Risk tolerance can be influenced by legal or regulatory requirements (Adapted from: ISO GUIDE 73). Risk tolerance and the level of risk that is acceptable to organizations or society are highly contextual and application and use-case specific. Risk tolerances can be influenced by policies and norms established by AI system owners, organizations, industries, communities, or policy makers. Risk tolerances are likely to change over time as AI systems, policies, and norms evolve. Different organizations may have varied risk tolerances due to their particular organizational priorities and resource considerations.

Emerging knowledge and methods to better inform harm/cost-benefit tradeoffs will continue to be developed and debated by businesses, governments, academia, and civil society. To the extent that challenges for specifying AI risk tolerances remain unresolved, there may be contexts where a risk management framework is not yet readily applicable for mitigating negative AI risks.

The Framework is intended to be flexible and to augment existing risk practices which should align with applicable laws, regulations, and norms. Organizations should follow existing regulations and guidelines for risk criteria, tolerance, and response established by organizational, domain, discipline, sector, or professional requirements. Some sectors or industries may have established definitions of harm or established documentation, reporting, and disclosure requirements. Within sectors, risk management may depend on existing guidelines for specific applications and use case settings. Where established guidelines do not exist, organizations should define reasonable risk tolerance. Once tolerance is defined, this AI RMF can be used to manage risks and to document risk management processes.

1.2.3 Risk Prioritization

Attempting to eliminate negative risk entirely can be counterproductive in practice because not all incidents and failures can be eliminated. Unrealistic expectations about risk may lead organizations to allocate resources in a manner that makes risk triage inefficient or impractical or wastes scarce resources. A risk management culture can help organizations recognize that not all AI risks are the same, and resources can be allocated purposefully. Actionable risk management efforts lay out clear guidelines for assessing trustworthiness of each AI system an organization develops or deploys. Policies and resources should be prioritized based on the assessed risk level and potential impact of an AI system. The extent to which an AI system may be customized or tailored to the specific context of use by the AI deployer can be a contributing factor.

Page 7

صفحة PDF الأصلية (من الملف).

نصها بعد التحويل

```
NIST AI 100-1

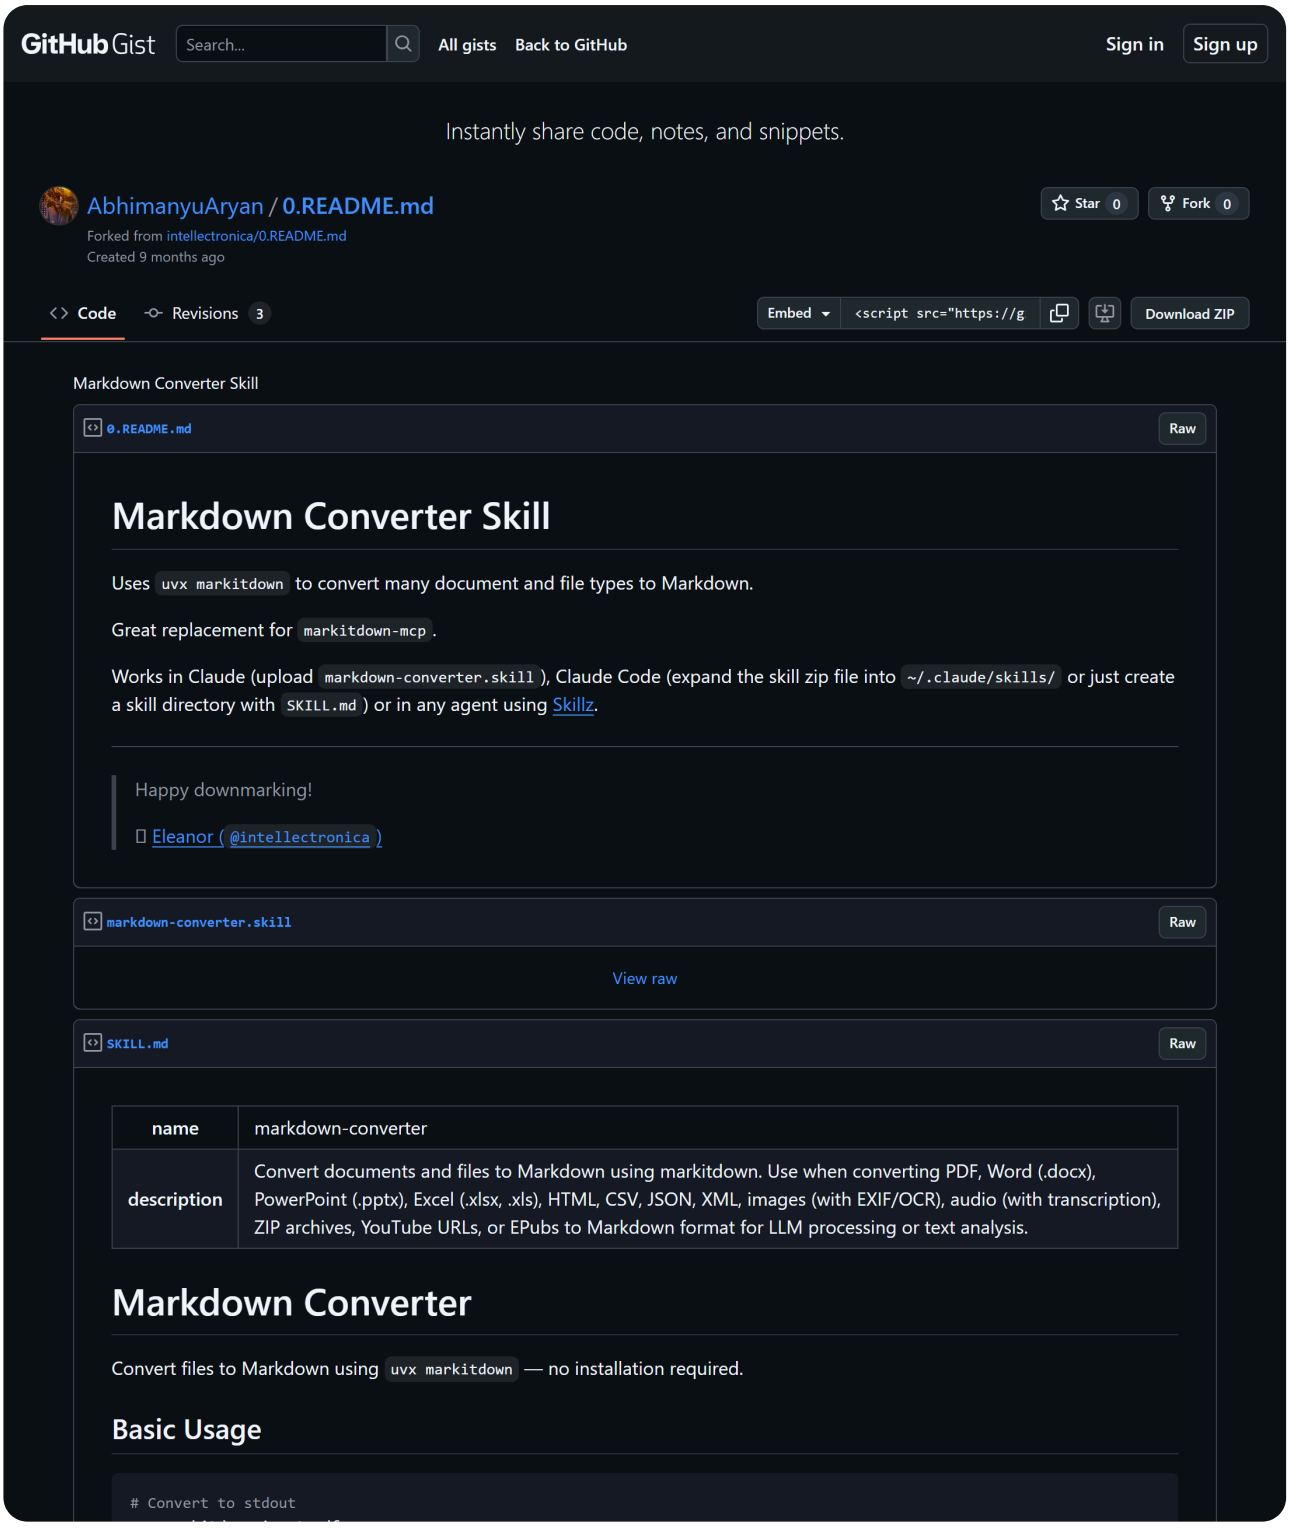
1.2.2 Risk Tolerance

While the AI RMF can be used
to prioritize
risk, it does not prescribe
risk tolerance.
Risk tolerance refers to the
organization's
or AI actor's readiness to
bear the risk...
```

جزء حقيقي من مخرج الأداة لنفس الصفحة (الصفحة 582 توكن تقريباً).

5. مهارة جاهزة لـ Claude

في مهارة (Skill) جاهزة على GitHub بتشغّل MarkItDown. هاي مهارة مجتمعية من Eleanor (@intellectronica) بتشتغل في Claude وفي Claude Code، وهي مش من Anthropic ولا من Microsoft.



المصدر: «Markdown Converter Skill» على GitHub Gist (ملف markdown-converter.skill، زر Raw للتنزيل).

كيف تضيفها لـ Claude (من لوحة Claude نفسها)

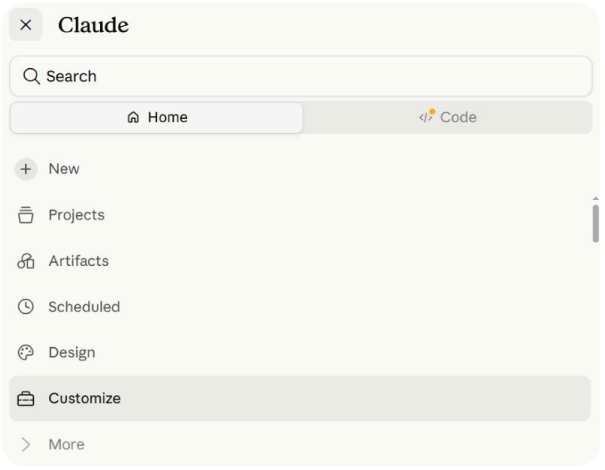
1. نزّل ملف المهارة من GitHub.

2 افتح **Customize** من القائمة الجانبية.

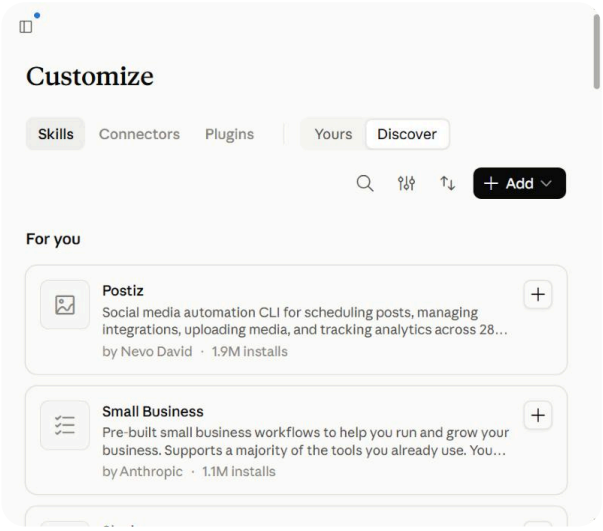
3 افتح تبويب **Skills**.

4 اضغط **Add skill**.

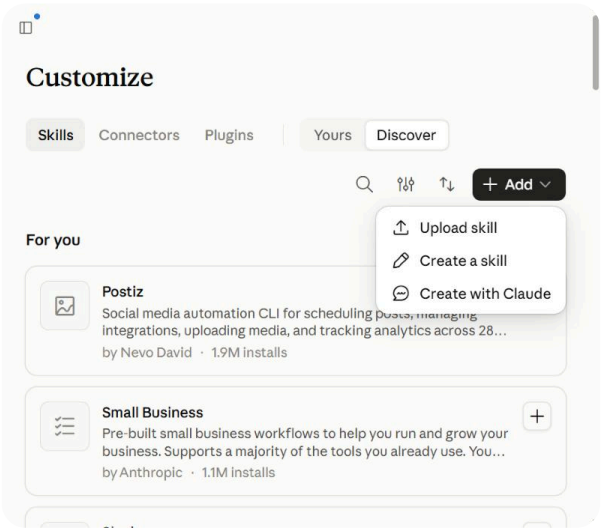
5 اختر **Upload skill** وارفع الملف.



Customize .1



Skills ← Add skill .2



Upload skill .3

المهارة بتشغّل الأداة بأمر `uvx markitdown` ، يعني لازم الأداة (uv) تكون متوفرة. وتنصيب المهارة ما بيثبّت الأداة لحاله. لتوفير حقيقي، حوّل الملف **قبل** ما يوصل لـ Claude.

6. الحدود (بصراحة)

- الصور والرسومات جوا الملف **ما بتنتقل**. الأداة بتطلّع النص: الرسم البياني في الصفحة بيروح ويبقى اسمه (Caption) بس.
- أحياناً بتطلع كلمتين ببعض بدون مسافة (حوالي 1% من الكلمات بالملف اللي قسناه). راجع النص قبل ما ترفعه.
- مناسبة للتقارير والعقود والنصوص. للتصاميم والإنفوجرافيك، ارفع الملف الأصلي.

المصادر

وثائق Anthropic (تكلفة PDF): platform.claude.com/docs/en/build-with-claude/pdf-support

MarkItDown: github.com/microsoft/markitdown

المهارة المجتمعية: gist.github.com/AbhimanyuAryan/2bf1336f51cbacfb238c00426857d760 (نسخة من gist لـ intellectronica)

الملف التجريبي: NIST AI 100-1 (منشور حكومي أمريكي مجاني)

دليل Anthropic لرفع المهارات: support.claude.com/en/articles/12512180
